

ASUS UGen · Intel® Arc™ Pro B70 32GB

把資料中心級的 AI 搬到你的桌機裡

Run AI Your Way — Local and Secure

32GB ECC 顯存的地端 AI 推論卡，給想自己養一隻大模型的資
工人

32GB GDDR6 ECC

256 組 XMX 引擎

PCIe 5.0 x16

校園技術分享 · 繁體中文版



為什麼要把模型跑在自己的機器上

01

雲端 GPU 永遠在排隊

免費額度用完、執行階段被回收，訓練到一半斷線重來。

02

API 用越多、帳單越長

Agent 一跑就是幾十萬 token，做實驗的成本無法預估。

03

資料不能往外送

校內研究資料、醫療與企業資料，法規上就不允許上雲。


04

顯存不夠，效能直接崩

VRAM 塞不下就得 offload 到主記憶體，推論效能可掉 10 倍以上。

一張 32GB 的卡，等於把「等 GPU」這件事從你的專題流程裡刪掉。

ASUS UGen Arc Pro B70 硬體規格總覽



32 GB

GDDR6 顯存 · 256-bit · 支援 ECC

608 GB/s

顯存頻寬

367 TOPS

INT8 算力 · FP32 22.94 TFLOPS

32 Xe 核心

256 組 XMX 矩陣引擎 · Xe2 架構

PCIe 5.0 x16

原生通道 · Boost 時脈 2800 MHz

290 W

TBP · 全高雙槽 · 12V-2x6 供電

顯示輸出 3× DisplayPort 2.1 + 1× HDMI 2.1b，最高 7680×4320@120Hz；多卡可堆疊至 128 GB 顯存。

資料來源：ASUS UGen Intel Arc Pro B70 32GB Datasheet v1.0 (Preliminary Specification，正式量產前可能調整)

為什麼它跑 AI 特別快：Xe2 與 XMX 引擎

XMX

256 組矩陣引擎，專吃 Transformer

LLM 推論的核心就是矩陣乘法。Xe2 架構搭配 32 個 Xe 核心與 256 組 XMX，在解碼與首字生成階段特別有優勢。

INT8


INT8 量化原生加速

367 INT8 TOPS。Q4 / Q8 量化模型可直接吃硬體加速，用更少顯存跑更大的模型。

ECC

支援 ECC 顯存


長時間推論或批次生成不會因為單一位元翻轉而毀掉整批結果，這是消費級遊戲卡沒有的保障。



全高雙槽散熱設計・雙滾珠軸承風扇・ASUS GPU Guard

實測：Token 生成速度 (MLPerf Client)

第二 Token 生成速率 (tok/s · 越高越好)




123 tok/s

MLPerf v6.0 推論 · 較 AMD R9700 快 7%

369 tok/s

50 人同時連線時的總吞吐量 (vLLM)

首字延遲 TTFT：使用者最有感的那一秒



0.08 秒

按下 Enter 到看見第一個字的等待時間，
比 AMD R9700 快 4.75 倍。

為什麼你該在意？

- 語音助理、即時對話 Agent 的體感好壞，幾乎由 TTFT 決定
- Agent 每一步都要重新 prefill，延遲會被放大數十倍

ComfyUI 出圖實測：30,000 張生成的統計驗證




圖 2 單張生成時間分佈直方圖，虛線為各組平均值（每卡 10,000 次生成）

三組分佈不重疊：UGen 最慢的一張仍快過另兩卡最快的一張。

5.2 兩兩比較 (Welch's t-test)

比較組合	均值差	差異	95% CI	d	p
UGen vs Intel 公版	-0.597 s	-10.6%	[-0.600, -0.593]	4.67	< .001
UGen vs AMD R9700	-1.416 s	-20.1%	[-1.419, -1.412]	11.19	< .001
Intel 公版 vs R9700	-0.819 s	-11.6%	[-0.822, -0.816]	7.62	< .001

負值表示前者較快。

全部達統計顯著

三組的 95% 信賴區間都不跨越 0，配對 t 檢定結論一致。

效果量極大

Cohen's d 介於 4.67–11.19，遠超「大效果」門檻 0.8。


同晶片，板卡設計差 10.6%

UGen 版與公版用同一顆 B70 晶片，差距來自散熱與功耗設計。

資料來源：ComfyUI 影像生成效能比較報告（2026-09-02），1024×1024、8 steps、相同 seed 序列。

32GB 顯存換到的是「上下文長度」

Llama 3.1 8B 可用上下文長度 (K tokens · 128K 為模型上限)



2.3 倍上下文

同樣 Q8_0 精度下，32GB 能載入的上下文是 16GB 卡的 2.3 倍。

BF16 也能吃 93K

不必犧牲精度換長度，長文件問答與長思維鏈一路跑到底。

多卡可到 128GB

1 / 2 / 4 卡彈性擴充，雙卡 64GB 已可跑 80B 級模型。

你可以拿它做什麼專題？

A

本地 LLM 推論

不連外網的程式助理、論文問答、課堂 Demo，模型完全跑在自己機器上。

llama.cpp (SYCL / Vulkan) · vLLM XPU · Ollama

B

Agentic AI 多代理並行

多個 Agent 同時跑，瓶頸從算力變成顯存，32GB 補上 KV Cache 缺口。

vLLM · 50 並行實測 369 tok/s

C

RAG 知識庫與 Embedding

把課程講義、論文、系辦文件做成可問答的私有檢索系統。

TEI · FastAPI · 向量資料庫

D

影像生成與多模態

ComfyUI 出圖、VLM 圖文問答、Whisper 語音轉寫與 OCR 文件理解。

ComfyUI 每分鐘 10.67 張 (1024px)

共同點：資料不出機器、成本不看帳單、想跑多久跑多久。

已驗證模型families：Llama 3.x、Qwen 3.x、DeepSeek-R1 Distill、Mistral / Mixtral、gpt-oss、InternVL3.5、Whisper-large-v3。

從一張卡到 128GB：需求長多大就疊多大

43.4

tok/s

雙卡 64GB 跑
Qwen3-Coder 80B 級模型

540

tok/s

四卡 128GB
一鍵腳本推論伺服器

82%

提升

72 人同時連線時
回應速度的提升幅度

3.0

tokens/W

17 個模型實測
峰值能效 (0.5B–46.7B)

1 / 2 / 4 卡：顯存池決定你能養多大的模型

單卡 32GB 已能涵蓋多數 27B 以下模型；雙卡 64GB 可跑 80B 級；四卡 128GB 供整個實驗室或部門共用。
模型權重以張量平行切分到多張卡上，對上層框架而言就像一張更大的卡。

不只是一張卡：隨附 UGen Console

開機健檢

驅動、硬體、環境三關逐項檢查。沒過不是只說失敗，而是就地給出處理步驟，連 Resizable BAR 要在 BIOS 哪裡開都寫給你。

狀態監看


顯存用量、GPU 使用率、以及溢出到系統記憶體的能力，一眼看完。

模型庫

官方型錄直接下載：SD 1.5、SDXL Base 1.0、FLUX.1 [schnell] GGUF、Qwen-Image GGUF、Wan 2.2 TI2V-5B。

ComfyUI 一鍵安裝

隨附 Python 與 Intel XPU 版 PyTorch，裝在獨立沙箱內，不動到你原本的系統環境，下載完模型就附上可直接開啟的起始工作流。




ComfyUI 安裝完成後的生圖環境

對學生的意義：不用花一個週末處理驅動與相依套件，插上卡就能開始做東西。

一台機器，整個實驗室一起用

場景：一張卡放在實驗室，全組同學共用同一批模型與同一個知識庫。



名稱	角色	Email	最近活動時間	建立於
Admin	管理員	user01@example.com	a few seconds ago	August 19, 2026
Designer A	使用者	user02@example.com	3 days ago	August 21, 2026
Marketing B	使用者	user03@example.com	3 days ago	August 27, 2026
Marketing C	使用者	user04@example.com	4 days ago	August 27, 2026
Engineer D	使用者	user05@example.com	3 days ago	August 28, 2026
Admin	使用者	user06@example.com	a minute ago	September 2, 2026
Engineer E	使用者	user07@example.com	3 days ago	September 4, 2026
Engineer E	使用者	user08@example.com	a few seconds ago	September 4, 2026

帳號、角色與群組管理

1,014 筆事件 · 驗證通過 · 觸發器完整

What is recorded

chat update 941 · chat insert 41 · chat delete 1 · knowledge insert 17 · knowledge delete 14

稽核記錄：累計筆數、各類操作分佈與驗證狀態

瀏覽器連入，零安裝

同學各自用瀏覽器連進來，共用這台機器上的模型，不必在自己的筆電裝任何東西。

帳號與群組管理

加入只要加進群組，不必逐份資料調權限；知識庫與模型預設私有，由管理員決定開放給誰。

各自的對話互不相見

同一台機器上，每個人的對話與檔案是分開的。


稽核記錄可驗證

誰、什麼時候、從哪裡改了什麼都留下紀錄，前後串接，事後竄改或缺漏查得出來。

把系上的文件變成可以問答的知識庫



文件問答：每一條回答都標出引用的來源檔案



對話裡做出來的應用，發布後就是一個網址

文件問答附來源

上傳講義、論文、系辦文件建索引後即可提問；資料裡沒有的內容會明說沒有。

對話裡直接生圖

用中文描述就生成圖片，還能指定要用哪一張卡。

程式碼當場執行

模型產生的 Python 在你瀏覽器的沙箱裡跑出結果，不碰到主機。


做完就能分享

留言板、看板、小遊戲發布後拿網址給同學就能開，大家看到同一份。

語音轉文字在本機

音訊不離開這台機器。

多卡調度、異常警示與遠端連線



主控台：四張卡各自的顯存、使用率、溫度、功耗與載入的模型

場景：人在宿舍，連回實驗室那台機器繼續跑。

指定卡片，或切分到多張

載入時可選自動配置、指定單卡，或跨卡切分。

顯存不足會擋下，不會踢掉別人

空間不夠時擋下載入並列出各卡剩餘容量。

每卡六項讀數 + 兩級警示

顯存、使用率、溫度、功耗、風扇與載入的模型，越線變色並給出處理動作。

實體辨識：讓那張卡自己發熱

在指定的卡上跑一段運算讓它發熱、風扇轉起來，機器旁的人就知道拔哪一張。

遠端連線三種狀態

關閉（僅限內網） / ASUS 通道 / 自有帳號，未驗證的連線一律拒絕。

你的軟體堆疊已經準備好了

1

llama.cpp — SYCL / Vulkan 後端

入門最快的一條路。實測 Vulkan 在每個模型尺寸都最穩，平均帶來 2.25× 加速

2

vLLM XPU 與 Intel LLM Scaler 容器

生產級服務部署，內建 INT4 / FP8 線上量化，不必外掛 CUDA 量化工具

3

OpenVINO + oneAPI

Intel 官方推論引擎，Windows / Linux 全平台，邊緣與企業部署首選

4

Ollama 與 PyTorch XPU

一行指令起服務；PyTorch XPU 已於 2025 年 GA，沿用你熟悉的寫法



你的下一個專題，不用再排隊等 GPU。

ASUS UGen · Intel® Arc™ Pro B70 32GB